

COMPTE-RENDU — TP 1

À remplir et à rendre

Identité

Nom(s) et prénom(s) : **ABANOUEAS REDA**

Filière / groupe : **2^{eme} Master BDIO**




Date : **26/09/2026** Option de dataset choisie (A / B / C) : **A**

Modèle PLM utilisé : **DistilBERT**

Résultats

Approche	Accuracy	F1	Temps d'entraînement	Coût (GPU / €)
A — Baseline (TF-IDF + LR)	0.9858	0.987	33.8789 s	33.8789/30h (Nvidia Tesla T4)
B — PLM gelé (features)	0.9905	0.9913	314.8092 s	314.8092/30h (Nvidia Tesla T4)
C — PLM fine-tuné (optionel)				
Bonus — LLM prompté	1.000	1.000	26.0801 s	26.0801 s (gemini 3.5 flash lite)

Matrice de confusion (coller une capture) :



Réponses aux questions

Q1. Les classes sont-elles équilibrées ? Quel impact sur le choix de la métrique (accuracy vs F1) ?

Les classes sont plus ou moins équilibrées (23481 Fake / 21417 Real)

Q2. Quel score obtient la baseline TF-IDF + régression logistique ?

Accuracy : 0.9856 / F1 : 0.987

Q3. PLM gelé vs baseline : quel gain ? Pourquoi les embeddings contextuels aident-ils ?

Le plm est plus performant que la baseline, puisqu'il peut comprendre le sens et non pas seulement les occurrences des mots

Q4. Fine-tuning vs PLM gelé : quel gain ? À quel coût (temps, GPU) ?

Q5. Matrice de confusion : quelles classes se confondent ? Donnez 2 exemples d'erreurs et une hypothèse.

Les modèles confondent la classe Fake plus que la classe Real (73 articles Fake mal prédit contre 38 articles Real mal prédite), même cas pour le plm

Q6. Quel modèle choisiriez-vous pour la production, et pourquoi (qualité, coût, latence) ?

Des prompts LLMs pourraient être coûteux avec plusieurs articles, et le plm prend du temps pour l'extraction des embeddings, dans ce cas la baseline classique suffit pour avoir de très bons résultats

Q7. Comment avez-vous évité le sur-apprentissage et la fuite test-in-train ?

La fuite test in train a été évitée en construisant le vocabulaire tfidf uniquement sur le dataset d'entraînement

Q8. Bonus : un LLM bien prompté fait-il mieux — ou moins cher — que votre PLM fine-tuné ?

Décision & justification

Modèle retenu pour la production et pourquoi (qualité / coût / latence, chiffres à l'appui) :

Baseline classique tfidf + régression logistique pour une précision et f1 suffisante par rapport au temps d'entraînement et coût GPU

Limites & pistes d'amélioration

Exploitation de la colonne 'subject' pour une meilleure prédiction et distinction des articles. Et entraînement avec des réseaux de neurones (ex : LSTM) ou modèles de classification avancés (SVM, Random Forest et XGBoost)